Национальный исследовательский университет "Высшая школа экономики"
Санкт-Петербургский филиал Санкт-Петербургской школы экономики и менеджмента

Курсовая работа

«Обнаружение сговора в запросах котировок»

Направления подготовки: 38.03.01 «Экономика»; 38.03.02 «Менеджмент»

Формат работы: исследовательская статья (Article format)

Бакалаврская программа “Международный бакалавриат по бизнесу и экономике”

Работа выполнена:

Кореньков Кирилл Валерьевич, группа БМББЭ2307С

Макаров Евгений Андреевич, группа БМББЭ2307С

Семчугов Андрей Евгеньевич, группа БМББЭ2307С

Руководитель

Департамент экономики

Молчанов Павел Сергеевич

Ефимов Константин Дмитриевич

Санкт-Петербург, 2026

Раскрытие использования генеративных моделей

Использованные модели. Anthropic Claude (https://claude.ai), OpenAI ChatGPT (https://chat.openai.com). Все запросы выполнялись на русском и английском языках в режиме веб-чата. Генеративные модели применялись точечно для отдельных вспомогательных задач, ни один раздел работы не был сгенерирован полностью. Авторы самостоятельно сформулировали исследовательский вопрос, выдвинули гипотезы, спроектировали методологию, провели сбор данных, реализовали программный код и интерпретировали полученные результаты.

Модели использовались для следующих задач:

1) Проверка внутренней согласованности текста. Готовый черновик подавался на вход модели с запросом найти противоречия между разделами (например, расхождения в числовых значениях, в формулировках гипотез, в характеристике моделей). Выявленные противоречия исправлялись авторами самостоятельно.
2) Перевод и адаптация формулировок из англоязычной литературы. Для отдельных фраз и терминов из источников на английском языке использовались Yandex.Переводчик, Google Translate и генеративные модели для контекстного перевода. Финальные формулировки редактировались авторами для соответствия академическому стилю русского языка.
3) Оформление таблиц и визуализаций. Генеративные модели использовались для подбора параметров отображения таблиц и графиков (цветовая палитра, разметка осей, экспорт в PNG). Содержательное наполнение таблиц определялось результатами расчетов авторов.

Применение генеративных моделей в указанных задачах позволило сократить время на редактуру и отладку кода, не повлияв на содержательную сторону исследования. Авторы оценивают эффект как умеренно положительный для качества оформления и грамотности текста; на эмпирические результаты и теоретическую часть работы применение моделей влияния не оказало.

Мы, Кореньков Кирилл Валерьевич, БМБ2307

Семчугов Андрей Евгеньевич, БМБ2307

Макаров Евгений Андреевич, БМБ2307

студенты 3 курса образовательной программы «Международный бакалавриат по бизнесу и экономике» Санкт-Петербургской школы экономики и менеджмента НИУ ВШЭ, подтверждаем, что курсовой проект на тему “Обнаружение сговора в запросах котировок” был выполнен нами самостоятельно, и:

1. не воспроизводит наши собственные предыдущие работы без указания их в качестве источника;
2. не воспроизводит работы других авторов без указания ссылки на источник учебной или научной литературы, статьи, веб-сайты, выполненные задания или конспекты других студентов;
3. ранее не представлялся для получения более высокого уровня образования;
4. содержит корректно оформленные и использованные цитаты и ссылки;
5. включает в себя полный библиографический список литературы и источников, которые были использованы при написании текста отчета по курсовому проекту.

Мы осознаем, что нарушение правил цитирования и оформления ссылок расценивается как обман или попытка введения в заблуждение, а также квалифицируется как нарушение Правил внутреннего распорядка НИУ ВШЭ

Раскрытие использования генеративных моделей 2
1. Аннотация 5
2. Введение 7
3. Обзор литературы 9
4. Методы и данные 12
4.1 Источник данных и формирование выборки 12
4.2 Конструирование признаков 13
4.3 Модели классификации и обработки дисбаланса 14
4.4 Схема валидации и метрики качества 15
5. Результаты 17
5.1 Предварительный анализ признаков 17
5.2. Сравнение моделей классификации 19
5.3. Матрицы ошибок ML моделей 22
5.4. Важность признаков 23
5.5. Кросс - валидация и устойчивость модели 25
5.6. Проверка гипотез 28
6. Обсуждение 29
6.1. Превосходство ансамблевых методов (H1) 29
6.2. Доминирование ценовых признаков (H2) 30
6.3. Роль структурных и графовых признаков (H3) 30
6.4. Устойчивость результатов и ограничения внутренней валидности 31
6.5. Обсуждение практических импликаций 33
7. Заключение 35
8. Список литературы 37
Приложение №1 39

1. Аннотация

Наша работа исследует применимость методов машинного обучения для обнаружения картельных сговоров в процедурах запроса котировок, проводимых в рамках 44-ФЗ. Запрос котировок широко используется как формат закупки, при котором участники подают однократные ценовые предложения. Такие предложения создают статичную ценовую среду, особенно уязвимую для координированного поведения. Несмотря на наличие правовой базы и полномочий Федеральной антимонопольной службы (ФАС), обнаружение картелей остается преимущественно реактивным процессом, инициированным только после поступления жалоб.

Датасет сформирован на 15 138 закупочных процедур, полученных путем сопоставления данных из Контур.Закупки с ФАС по делам о нарушении статьи 11 ФЗ-135. Закупка размечается как картельная (is_cartel = 1), если ИНН ее победителя фигурирует в решениях антимонопольного органа. Доля картельных наблюдений составляет 1,7 %, что определяет выраженный дисбаланс классов. Из протоколов закупок конструируются три группы признаков: ценовые (процент снижения цены, отношение цены договора к начальной максимальной цене контракта), графовые (доля несостоявшихся торгов в регионе, концентрация победителя в регионе, накопленная история побед поставщика) и структурные (логарифм начальной максимальной цены, признак несостоявшихся торгов, частота региона).

Обучаются и сравниваются три семейства моделей классификации, из которых выделяется логистическая регрессия в качестве линейного бенчмарка, Random Forest и XGBoost. Для борьбы с дисбалансом был применен алгоритм SMOTE для синтетической балансировки обучающей выборки и взвешивание классов. Качество оценивается по метрикам Precision, Recall, F1-score на отложенной тестовой выборке. Ансамблевые модели существенно превосходят логистическую регрессию по F1-score. Наилучшую сбалансированную метрику, которую мы получили по F1 - score показал Random Forest на графовых признаках с подбором гиперпараметров (F1 = 0,270, Recall = 0,529) против F1 = 0,059 у линейного бенчмарка. XGBoost на графовых признаках достигает наивысшей полноты (Recall = 0,627) и наилучшего значения Average Precision (AP = 0,311), верно выявляя 32 картеля из 51 при сохранении умеренной точности. Выбор между моделями определяется приоритетом регулятора, если важен баланс точности и полноты, то целесообразно выбрать Random Forest, а вот если максимизация полноты выявления, то

XGBoost. Для повышения надежности оценок гипер параметры модели Random Forest подбирались с помощью пятикратной стратифицированной кросс-валидации (RandomizedSearchCV, cv=5) на обучающей выборке, что исключает утечку информации из тестовой части. Анализ важности признаков проявляет ценовые характеристики как внесение наибольшего вклад в предсказание - отношение цены договора к НМЦ и процент снижения цены. Результаты подтверждают принципиальную возможность перехода от реактивного к проактивному скрининговому мониторингу государственных закупок.

2. Введение

Объектом исследования в нашей работе выступает процесс проведения государственных и корпоративных закупок. Предметом исследования же является процедура запроса котировок как одна из наиболее распространенных и формализованных форм закупочной деятельности.

С точки зрения теории аукционов запрос котировок относится к закрытым аукционам первой цены (sealed-bid first-price auction), где участники однократно подают запечатанные ценовые заявки, не имея информации о предложениях конкурентов, а побеждает участник с наименьшей ценой, и контракт заключается по этой же цене. Принципиальное отличие от открытых аукционов (например, английского аукциона на понижение, используемого в электронных аукционах по 44-ФЗ) состоит в отсутствии итеративных торгов. Участник не может пересмотреть свою ставку в ответ на действия конкурентов. Эта особенность определяет двойственный характер процедуры. С одной стороны, закрытый формат снижает транзакционные издержки и ускоряет проведение закупки. С другой, отсутствие наблюдаемой ценовой динамики делает запрос котировок структурно уязвимым к картельному сговору, так как для поддержания соглашения участникам не требуется реагировать на отклонения партнеров по картелю в реальном времени, что снижает риск раскрытия согласованной стратегии и устойчиво поддерживает картель во времени (Decarolis, Giorgiantonio, 2022; Ishii, 2007).

Исследование актуально, поскольку сфера закупок в настоящее время переходит на цифровой формат, в это же время в литературе последних лет обсуждается применение машинного обучения для выявления коррупции в закупках. Наша работа проверяет применимость ML-методов скрининга на российских закупочных данных и опирается на нормативно-правовую базу РФ (44-ФЗ, 223-ФЗ, ст. 11 135-ФЗ) и современные эконометрические методы обнаружения сговоров.

Проблема: Существующие методы выявления картельных сговоров, применяемые ФАС, ограничены возможностями ручного анализа огромных массивов данных и задействуются лишь после поступления жалоб. Скрытые соглашения между участниками искажают рыночные цены и наносят урон бюджету, при этом существующие правовые рамки (44-ФЗ; 223-ФЗ) требуют более эффективных инструментов контроля. Объем государственных и корпоративных закупок в России стабильно составляет около 27% ВВП

(ТАСС, 2021), в то время как коррупционные потери в этой сфере оцениваются в 6,6 трлн рублей ежегодно (Головщинский и Шамрин, 2021), что делает автоматизацию антимонопольного контроля критически важной задачей.

Цель: Оценить применимость автоматизации процесса обнаружения недобросовестной конкуренции с помощью алгоритмов машинного обучения.

RQ: Может ли модель машинного обучения эффективно классифицировать закупки по признаку «сговор / отсутствие сговора» на основе структурных и ценовых характеристик запросов котировок?

Работа организована следующим образом. В третьем разделе представлен обзор литературы по методам обнаружения картелей в закупках и сформулированы гипотезы исследования. Четвертый раздел описывает процесс сбора данных, конструирование признаков и выбор моделей классификации. В пятом разделе представлены результаты моделирования. В шестом разделе результаты обсуждаются в контексте предшествующих исследований и проверяются выдвинутые гипотезы. Седьмой раздел завершает работу выводами, ограничениями и направлениями дальнейших исследований.

3. Обзор литературы

Картелями в госзакупках исследователи занялись всерьез еще с начала 2000-х. Подход за это время заметно изменился. Систематический обзор Lyra et al. (2022) фиксирует сдвиг от классической эконометрики к методам, основанным на данных, что означает, что объемы закупочной информации стали такими, что вручную и стандартной статистикой коррупционные схемы уже не выловить.

Главный вопрос - какие именно черты закупочной процедуры делают ее удобной для сговора. Ishii (2007) на японском рынке дорожного строительства показал, что все дело в стабильном составе участников и регулярности торгов, то есть одни и те же фирмы раз за разом встречаются на одних площадках, договориться им становиться намного проще. Decarolis и Giorgiantonio (2022) пришли к похожему выводу на итальянских данных, ключевым фактором риска у них оказалось отсутствие ценовой динамики в ходе торгов. Вывод у обеих работ дают нам четкое представление, что процедуры с однократной подачей цены, к которым относятся и запросы котировок, наиболее уязвимы к сговору.

Раз ручной контроль со своими объемами не справлялся, исследователи стали искать автоматизацию процесса. Одними из первых экономическую теорию с машинным обучением соединили Huber и Imhof (2019). Они собрали набор ценовых маркеров сговора - коэффициент вариации ставок, разрыв между первой и второй ценой, отклонение от закона Бенфорда и показали, что вместе с ML-классификаторами эти признаки неплохо ловят манипуляции со ставками на швейцарских данных. Примерно тогда же Ralha и Silva (2012) построили мультиагентную систему скрининга бразильских закупок и доказали, что подход тянется до национального масштаба.

Какие алгоритмы лучше всего классифицируют закупки, подробно проверили García Rodríguez et al. (2022). Они прогнали 11 моделей на испанских данных, и ансамблевые методы Random Forest и XGBoost уверенно обошли логистическую регрессию, SVM и нейросети. Barot (2023) на канадских данных получил один и тот же результат. У него бустинг не только сильнее остальных классификаторов, но и устойчив к дисбалансу классов. Rodríguez et al. (2020) зашли с другой стороны и построили рекомендательную систему, которая оценивает надёжность участников по их прошлому поведению. Мы сделали очень важный вывод для своей работы, что для табличных закупочных данных ансамбли это предпочтительный инструмент.

Отдельное направление литературы посвящено проблеме неполных картелей, когда не все фирмы на рынке участвуют в сговоре. Wallimann, Imhof и Huber (2022) пошли в сторону неполных картелей. Их идея заключается в том, что даже если мы не знаем точный состав сговора, по совместному участию фирм в торгах его можно вычислить. Wallimann и Sticher (2023) проверили этот же подход на закупках железнодорожной инфраструктуры и нашли подозрительные паттерны у поставщиков, которые до этого вообще не были замечены антимонопольной службой. Выводы из этих работ принципиально важны для нашего исследования, поскольку разметка на основе дел ФАС заведомо фиксирует лишь часть реально существующих соглашений.

Самые сложные модели в этой области - нейросетевые. Huber и Imhof (2021) предложили подавать распределение ставок в свёрточную нейросеть (CNN) как картинку, где сеть улавливает в форме распределения аномалии, которые классические алгоритмы не видят. Imhof, Viklund и Huber (2025) не остановились только на этом результате и применили графовые нейросети с механизмом внимания (GAT), который учитывает не только цены отдельных закупок, но и всю сеть связей между компаниями. Их модель показала точность 91% при переносе на рынки других стран. Это говорит о хорошей обобщающей способности, а значит, подход в принципе может сработать и на российских данных.

Есть и третья сторона сговора, которую разбирают в литературе, то, как фирмы ведут себя на самих торгах. Andres, Bruttel и Friedrichsen (2023) указали на это экспериментально: у фирм, которые реально сговорились, в поведении на торгах остается характерный след, и ML отличает настоящий сговор от случайного совпадения цен именно по нему. Sadoune, Joanis и Lodi (2024) обозначили совсем новую проблему алгоритмического сговора, когда координируют уже не люди, а ИИ-агенты без прямого участия человека. Для антимонопольных органов это отдельная головная боль.

Видно, что методы обнаружения картелей развивались по нарастающей, от экономических маркеров к классическому ML, потом к глубокому обучению и графовым нейросетям. Но почти все эти работы построены на зарубежных данных . Будет ли подход работать на российских закупках?. Вопрос открытый, и именно он лег в основу нашего исследования.

На основании проведенного обзора литературы сформулированы следующие гипотезы:

(García Rodríguez et al., 2022) продемонстрировали, что ансамблевые методы, в частности Random Forest и XGBoost стабильно превосходят другие классификаторы при определении сговора в закупочных данных. (Barot, 2023) обосновал превосходство бустинг моделей над традиционными классификаторами на современных данных. Результаты стимулируют к выдвижению первой гипотезы:

H1: Random Forest и Gradient Boosting превосходят логистическую регрессию по метрике F1-score на задаче классификации закупок

(Huber & Imhof, 2019) зафиксировали ценовые сигналы как наиболее информативные индикаторы сговора, в особенности коэффициент вариации поданных ставок и разрыв между ценой победителя и второго участника. Подход, объединяющий классические экономические метки с алгоритмами ML, установил, что именно паттерны ценовой дисперсии несут наиболее сильный предсказательный сигнал. Отсюда вторая гипотеза:

H2: Ценовые признаки - относительное снижение цены победителя по сравнению с НМЦ и отношение цены договора к НМЦ вносят наибольший вклад в предсказание сговора.

(Ishii, 2007) показал, что стабильность состава участников и повторяемость торгов создают благоприятную среду для поддержания картелей в повторяющихся закупочных процедурах. (Wallimann et al., 2022) презентовали способность ML алгоритмов выявлять неполные картели, опираясь на паттерны совместного участия даже тогда, когда не все фирмы вовлечены в соглашение. Результаты свидетельствуют о том, что регулярное совместное участие является структурным признаком сговора:

H3: Компании, которые регулярно участвуют в одних и тех же закупках вместе, с большей вероятностью являются участниками картеля

4. Методы и данные

Для исследования будет использован четырехэтапный анализ данных:

1) Сбор и обработка данных. В качестве главного источника протоколов запросов котировок будет использован ФАС, а также после выгрузки данных будет задействована чистка от дублей
2) Конструирование признаков. Сырые данные из протоколов будут переведены в числовые признаки, указывающие на сговор
3) Обучение моделей. Тестируются классические алгоритмы (Random Forest, Gradient Boosting) и перспективные - графовые нейросети (GAT)
4) Интерпретация полученных результатов. Проводится оценка точности моделей и интерпретация их решений.

Все вычисления выполнены на языке Python с использованием библиотек pandas, NumPy и scikit-learn, полный код приведен в Приложении 1.

4.1 Источник данных и формирование выборки

Эмпирическую базу составляют протоколы процедур запроса котировок, выгруженные из Контур.Закупки. После выгрузки данные прошли очистку от дубликатов и записей с отсутствующими ключевыми полями. Итоговая выборка содержит 15 138 закупочных процедур, проведенных в рамках 44-ФЗ (около 92 % наблюдений) и 223-ФЗ. Начальная максимальная цена контракта варьируется в широком диапазоне, от нескольких десятков рублей до 230 млн рублей при медианном значении около 157 тыс. рублей, что указывает на сильную правостороннюю асимметрию распределения. Закупки охватывают 82 региона Российской Федерации.

Разметка целевой переменной выполнена путем сопоставления выборки с решениями Федеральной антимонопольной службы по делам о нарушении статьи 11 Федерального закона № 135-ФЗ. Закупка получает метку is_cartel = 1, если ИНН ее победителя присутствует в перечне хозяйствующих субъектов, признанных нарушителями антимонопольного законодательства, и is_cartel = 0 в противном случае. Из 15 138 наблюдений картельными признаны 254 (1,7 %), что соответствует выраженному дисбалансу классов: 14 884 закупок отнесены к классу «без сговора» и 254 - к классу «картель».

Примечательно, что доля картельных закупок 1,7 % аналогична показателям зарубежной литературы на похожих данных. Около 2 % в швейцарской выборке у Huber и Imhof (2019), менее 3 % в бразильских закупках у Ralha и Silva (2012), около 1 % в испанских данных у García Rodríguez et al. (2022). Низкая доля отражает не недостаток выборки, а реальную распространенность доказанных случаев сговора и одновременно подчеркивает практическую ценность задачи, что модель, выделяющая среди тысяч закупок небольшое подмножество с повышенной концентрацией картелей позволяет сосредоточить ограниченные ресурсы контролера именно на нем.

Выраженный дисбаланс классов это характерная особенность задачи обнаружения картелей. (Barot, 2023) определяет два методологических следствия. Прежде всего, метрика accuracy (доля верных ответов) неинформативна, так как модель, относящая все закупки к классу «без сговора», достигла бы точности 98,3 %, не обнаружив ни одного картеля. Поэтому качество оценивается по метрикам Precision, Recall, F1-score и AUC-ROC. Более того, требуется специальная обработка дисбаланса на этапе обучения.

Важно учитывать, что разметка по делам ФАС обладает свойством неполноты, а именно, что антимонопольный орган фиксирует лишь те соглашения, которые были освещены и доказаны. Следовательно, часть наблюдений с меткой is_cartel = 0 в действительности может относиться к нераскрытым картелям. Это ограничение типично для литературы (Wallimann et al., 2022) и обсуждается в разделе 7.

4.2 Конструирование признаков

Из протоколов закупок сконструированы признаки трех содержательных групп. Поскольку картельное поведение проявляется не в отдельной закупке, а в устойчивом паттерне, наряду с признаками отдельной процедуры рассчитаны агрегированные графовые признаки, характеризующие поведение победителя и региона по всей выборке.

1) *Структурные и ценовые признаки отдельной закупки:*

- log_НМЦ - натуральный логарифм начальной максимальной цены контракта. Логарифмирование устраняет правостороннюю асимметрию распределения цен.
- несостоявшаяся - бинарный индикатор того, что торги признаны несостоявшимися (никто не подал заявку, либо подан единственный участник). Это главный поведенческий признак бойкота торгов, среди несостоявшихся процедур доля картельных достигает 3,1 % против 0,6 % среди завершенных.
- процент_снижения - относительное снижение цены победителя по сравнению с НМЦ. При честной конкуренции снижение, как правило, выражено, при сговоре оно минимально.

- цена_к_нмц - отношение фактической цены договора к НМЦ, ограниченное диапазоном [0; 2]. Значение, близкое к единице, указывает на заключение контракта практически без торга.
- регион_freq - частота региона в выборке (доля закупок региона от общего числа наблюдений), отражающая интенсивность закупочной активности территории.
- месяц - порядковый номер месяца публикации закупки, учитывающий возможную сезонность.

2) *Графовые признаки, агрегированные по всей выборке:*

- регион_доля_несостоявшихся - доля несостоявшихся торгов в регионе. Высокое значение может свидетельствовать о том, что закупочный рынок региона контролируется ограниченным кругом поставщиков.
- победитель_концентрация_в_регионе - доля побед самого частого поставщика среди завершенных торгов региона, высокое значение указывает на фактическую монополизацию.
- победитель_побед_всего - суммарное количество побед данного ИНН во всей выборке.
- победитель_побед_в_регионе - количество побед данного ИНН в конкретном регионе, устойчивое доминирование на локальном рынке это структурный маркер возможного сговора.
- победитель_доля_несостоявшихся - доля несостоявшихся торгов среди побед данного поставщика. Компания, выигрывающая преимущественно там, где нет конкурентов, представляет повышенный интерес для контроля.

Пропущенные значения числовых признаков заполнены нулями для несостоявшихся процедур (где победитель и, соответственно, цена договора отсутствуют) и медианными или нейтральными значениями в остальных случаях. Для последующего сравнительного анализа выделены два набора признаков: базовый (6 признаков отдельной закупки) и расширенный графовый (11 признаков, включающий базовый набор и 5 агрегированных характеристик).

4.3 Модели классификации и обработки дисбаланса

В соответствии с выводами обзора литературы для сравнения выбраны три семейства классификаторов.

1) Логистическая регрессия используется в качестве базовой модели (бенчмарка), задающей линейную точку отсчета для оценки более сложных моделей. Признаки

предварительно стандартизированы, а также применено взвешивание классов (class_weight = 'balanced').

2) Random Forest это ансамбль решающих деревьев, обученных на бутстрэп-выборках со случайным отбором признаков. Метод хорошо работает с табличными данными и устойчив к выбросам (García Rodríguez et al., 2022). Гиперпараметры (число деревьев, максимальная глубина, минимальный размер листа) подобраны процедурой рандомизированного поиска RandomizedSearchCV с оптимизацией F1-score на стратифицированной кросс-валидации.
3) XGBoost (Extreme Gradient Boosting) это последовательный ансамблевый метод, итеративно исправляющий ошибки слабых моделей. В отличие от случайного леса, бустинг строит деревья последовательно, каждое следующее дерево фокусируется на наблюдениях, на которых предыдущие деревья ошибались. Для борьбы с дисбалансом классов в XGBoost применяется параметр scale_pos_weight, который штрафует ошибки на миноритарном классе пропорционально их редкости.

Проблема дисбаланса классов была решена проактивно с применением двух взаимодополняющих методов, каждый из которых удовлетворяет природе конкретного алгоритма. Для Random Forest используется алгоритм SMOTE (Synthetic Minority Over-sampling Technique), реализованный в библиотеке imbalanced-learn. SMOTE генерирует синтетические наблюдения миноритарного класса не путем простого дублирования, а интерполяцией между близкими картельными наблюдениями в пространстве признаков, что обеспечивает большее разнообразие обучающей выборки и снижает риск переобучения. После применения SMOTE обучающая выборка для Random Forest содержит 23 814 наблюдений с равным соотношением классов (по 11 907 каждого). Для логистической регрессии и XGBoost применяется взвешивание классов. В логистической регрессии это параметр class_weight = 'balanced', а в XGBoost же параметр scale_pos_weight, равный отношению числа некартельных наблюдений к числу картельных в обучающей выборке (58,7). Таким образом, ни одна из моделей не обучается на исходном несбалансированном распределении без определенной коррекции. Стоит сказать, что балансировка применяется исключительно к обучающей выборке, то есть тестовая выборка сохраняет исходную пропорцию классов, что обеспечивает корректность оценки качества.

4.4 Схема валидации и метрики качества

Выборка разделена на обучающую и тестовую части в пропорции 80/20 со стратификацией по целевой переменной (random_state = 42). Стратификация сохраняет

долю картельных наблюдений в обеих частях. Обучающая выборка содержит 12 110 закупок (203 картельных), тестовая - 3 028 закупок (51 картельная). Подбор гиперпараметров Random Forest выполнен на пятиблочной стратифицированной кросс-валидации внутри обучающей выборки, что исключает утечку информации из теста.

Качество моделей оценивается по трем основным метрикам. Precision (точность) это доля действительных картелей среди всех закупок, помеченных моделью как картельные, где высокая точность означает малое число ложных срабатываний. Recall (полнота) - доля выявленных картелей от их общего числа, где высокая полнота означает, что модель пропускает мало реальных сговоров. F1-score - гармоническое среднее точности и полноты, основная агрегированная метрика для несбалансированных задач. Метрика accuracy (доля верных ответов) сознательно не используется как основная, так как при доле картельных закупок 1,7 % тривиальный классификатор, относящий все закупки к классу «без сговора», достиг бы точности 98,3 %, не обнаружив ни одного картеля. Дополнительно отслеживаются абсолютные числа верно выявленных картелей (TP) и ложных срабатываний (FP), наглядно показывающие практическую отдачу модели. Интерпретация моделей проводится через анализ важности признаков.

5. Результаты

В разделе 5 приведено описание результатов сравнительного анализа моделей без их содержательной интерпретации, обсуждение же результатов в контексте предыдущих исследований представлено в разделе 6.

5.1 Предварительный анализ признаков

Различия в распределениях ключевых ценовых признаков между классами наглядно иллюстрируют графики плотности (Рис. 1). Распределение отношения цены договора к начальной максимальной цене у картельных закупок имеет ярко выраженный пик в области значений, близких к единице, в то время как у некартельных закупок распределение более пологое и имеет дополнительный пологий максимум в диапазоне 0,6-0,8. Это означает, что при сговоре контракт почти всегда заключается практически без торга, тогда как при честной конкуренции снижение цены варьируется в широком диапазоне. Распределение процента снижения цены подтверждает ту же закономерность с обратной стороны. У картельных закупок плотность сосредоточена у нуля, у некартельных имеет выраженный хвост в области 0,1-0,5. Пунктирными линиями отмечены средние значения каждого класса, где 0,82 против 0,94 для отношения цены к НМЦ и 0,14 против 0,05 для процента снижения цены.

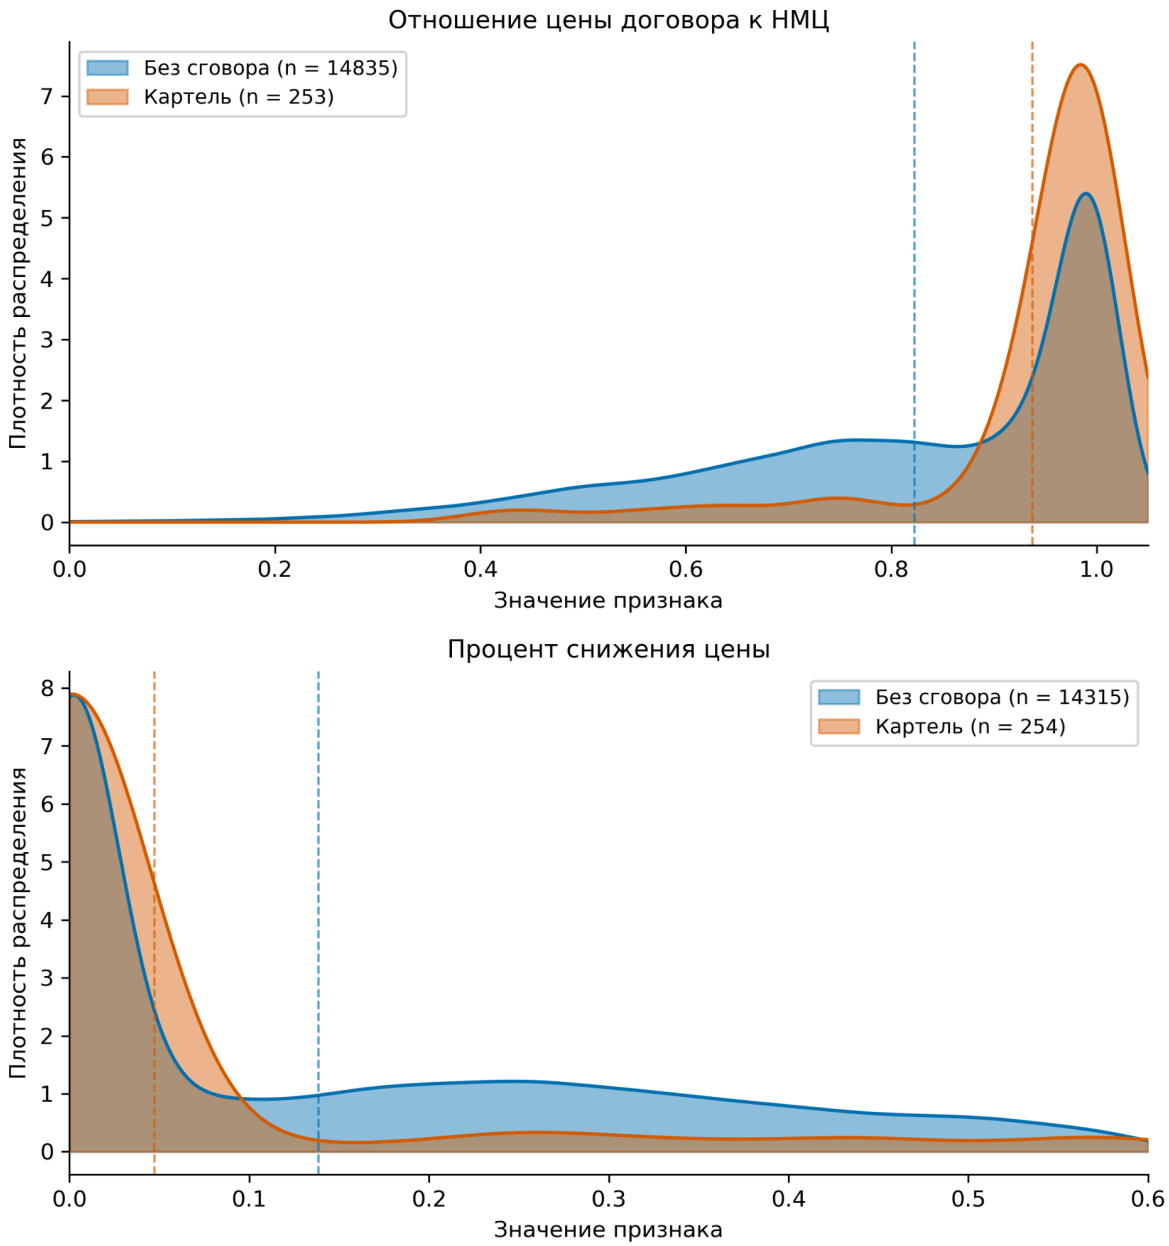


Рис. 1. Распределение ценовых признаков по классам

Помимо ценовых признаков, важное различие между классами обнаруживается в признаке не состоявшихся торгов, из 254 картельных закупок 199 (78 %) признаны не состоявшимися против 38 % среди некартельных. При этом парные линейные корреляции всех признаков с целевой переменной по абсолютной величине не превышают 0,10, что указывает на нелинейный характер связи признаков со сговором и обосновывает выбор ансамблевых моделей. Перед изложением результатов классификации необходимо ввести понятие важности признаков, на которое опирается интерпретация моделей в разделах 5.2 и 5.4. Важность признака (feature importance) это численная мера того, насколько часто и насколько эффективно модель использует данный признак при принятии решений. У Random Forest важность рассчитывается как Gini importance, что означает суммарное

уменьшение примеси Джини при разбиениях по этому признаку, усредненное по всем деревьям ансамбля. У XGBoost применяется gain-based importance, то есть суммарный прирост качества модели, обеспечиваемый признаком при всех его использованиях в деревьях. В обоих случаях значения нормированы так, что их сумма равна единице, а более высокое значение означает больший вклад признака в итоговое предсказание модели.

5.2. Сравнение моделей классификации

Результаты пяти конфигураций моделей на отложенной тестовой выборке (3 028 закупок, 51 картельная) представлены в Таблице 1.

Модель	Precision	Recall	F1-score	TP	FP
Логистическая регрессия (бенчмарк)	0,031	0,706	0,059	36	1128
Random Forest - базовые признаки	0,154	0,471	0,232	24	132
Random Forest - граф + RandomSearch	0,181	0,529	0,270	27	122
XGBoost - базовые признаки	0,109	0,490	0,178	25	205
XGBoost - граф-признаки	0,123	0,627	0,206	32	228

Таблица 1. Сравнение моделей классификации на тестовой выборке (TP - верно выявленные картели, FP - ложные срабатывания)

По метрике F1-score все четыре ML-модели превосходят логистическую регрессию. F1 у Random Forest на графовых признаках составляет 0,270 против 0,059 у линейного бенчмарка, а именно превосходство более чем в четыре раза. Логистическая регрессия достигает высокой полноты (Recall = 0,706, верно выявлено 36 картелей), однако при крайне низкой точности (Precision = 0,031): из 1 164 закупок, помеченных моделью как картельные, действительными картелями являются лишь 36, то есть на одно правдивое срабатывание приходится около 31 ложного. Random Forest на графовых признаках демонстрирует наилучшую сбалансированную метрику F1, верно выявляя 27 картелей из 51 при 122 ложных срабатываниях. XGBoost на графовых признаках демонстрирует наивысшую полноту среди всех моделей (Recall = 0,627), верно выявляя 32 картеля из 51,

но ценой большего числа ложных срабатываний (228). XGBoost на базовых признаках занимает промежуточное положение (F1 = 0,178, верно выявлено 25 картелей).

Добавление графовых признаков улучшает качество обеих ансамблевых моделей. Для Random Forest F1-score возрастает с 0,232 до 0,270, число верно выявленных картелей с 24 до 27, а число ложных срабатываний снижается со 132 до 122. Для XGBoost F1-score возрастает с 0,178 до 0,206, число верно выявленных картелей с 25 до 32 (рост на 28 %), при относительно небольшом увеличении ложных срабатываний с 205 до 228. На кросс-валидации при подборе гиперпараметров Random Forest наилучшая конфигурация (363 дерева, max_depth = 29, min_samples_leaf = 1) составила 0,975 при F1-score, что существенно превышает F1 на отложенной тестовой выборке (0,270). Этот разрыв обсуждается в разделе 6.4.

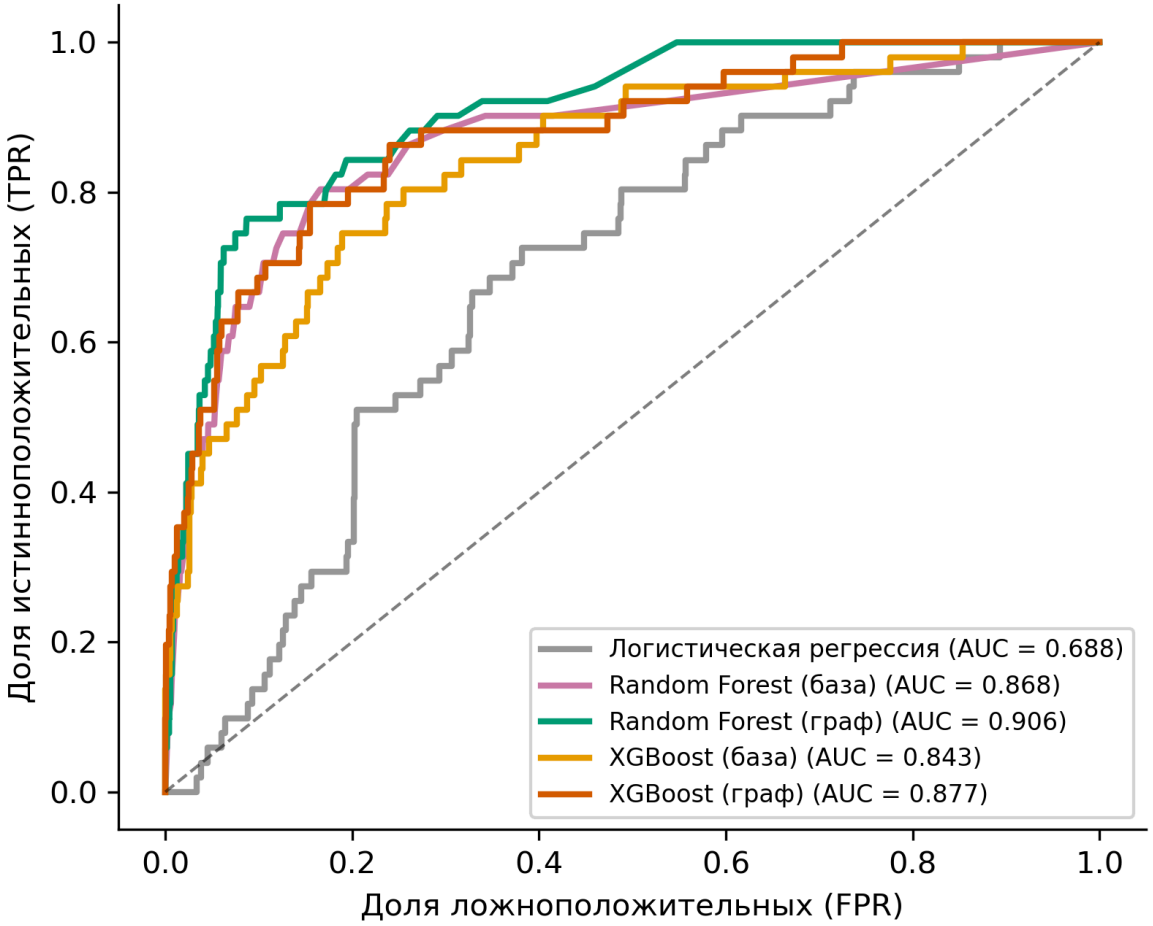


Рис. 2. ROC-кривые моделей классификации

ROC-кривые (Рис. 2) показывают, что кривые ансамблевых моделей на всем диапазоне порогов проходят выше кривой логистической регрессии. Это означает, что при любом фиксированном уровне ложных срабатываний ансамблевые модели обеспечивают более высокую полноту выявления картелей, чем линейный бенчмарк, и что превосходство ансамблей не зависит от конкретного выбора порога классификации.

XGBoost на графовых признаках достигает AUC = 0,877, Random Forest на графовых признаках 0,906, что существенно превышает AUC = 0,688 у логистической регрессии.

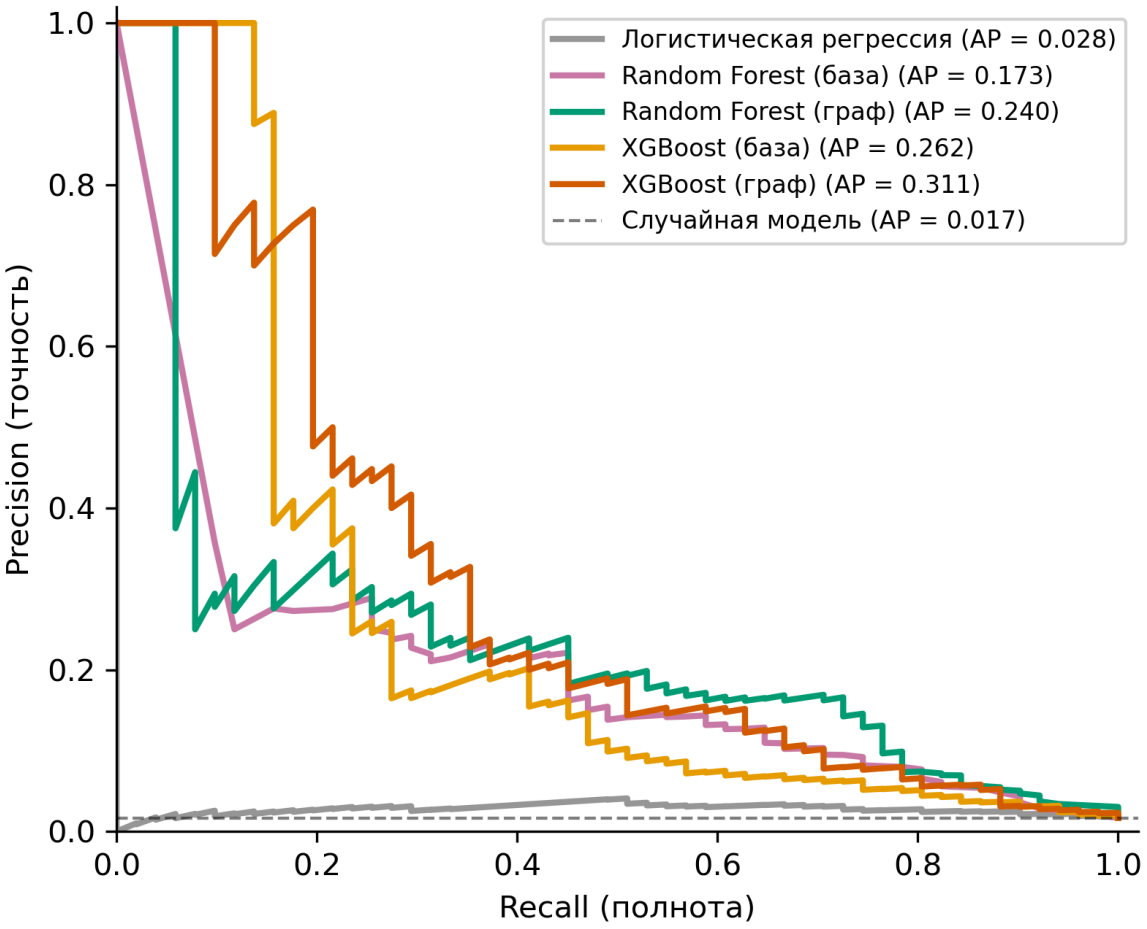


Рис. 3. Precision-Recall кривые моделей классификации

Дополнительной мерой качества при выраженном дисбалансе классов служит Precision-Recall кривая (Рис. 3) и связанная с ней метрика Average Precision (AP) - площадь под PR-кривой. В отличие от ROC-кривой, которая может оптимистично оценивать качество при малой доле положительного класса, PR-кривая показывает истинный компромисс между точностью и полнотой именно для выявления редкого класса. По метрике AP наилучший результат демонстрирует XGBoost на графовых признаках (AP = 0,311), за ним следуют XGBoost на базовых признаках (0,262), Random Forest на графовых признаках (0,240) и Random Forest на базовых признаках (0,173). Логистическая регрессия (AP = 0,028) лишь незначительно превосходит случайную модель (AP = 0,017), что наглядно иллюстрирует ее непригодность для нашей задачи. По соотношению ансамблевых моделей AP подтверждает наблюдение, сделанное по другим метрикам, а именно добавление графовых признаков улучшает качество обеих моделей, в то время как XGBoost оказывается сильнее Random Forest в средней области порогов классификации.

5.3. Матрицы ошибок ML моделей

Матрицы ошибок четырех ML-моделей на тестовой выборке представлены на Рис. 4. Каждая матрица показывает, как модель распределила 3 028 закупок тестовой выборки между четырьмя категориями. Верные предсказания на некартельных закупках (TN, левый верхний квадрант), ложные срабатывания (FP, правый верхний), пропущенные картели (FN, левый нижний) и верно выявленные картели (TP, правый нижний).

Random Forest на базовых признаках достоверно классифицирует 24 картеля из 51 (TP) при 132 ложных срабатываниях (FP), то есть добавление графовых признаков повышает число выявленных картелей до 27 и одновременно снижает число ложных срабатываний до 122. Принципиально важно, что прирост достигается не за счет смещения порога классификации, а за счет более информативного признакового пространства, модель одновременно ловит больше картелей и с меньшей периодичностью ошибается на некартельных закупках.

XGBoost ведет себя иначе. На базовых признаках он выявляет 25 картелей при 205 ложных срабатываниях, на графовых признаках - 32 картеля, что является лучшим результатом среди всех моделей при 228 ложных срабатываниях. Бустинг систематически дает больше TP за счет большего числа FP, что отражает агрессивную работу параметра scale_pos_weight = 58,7 в условиях экстремального дисбаланса.

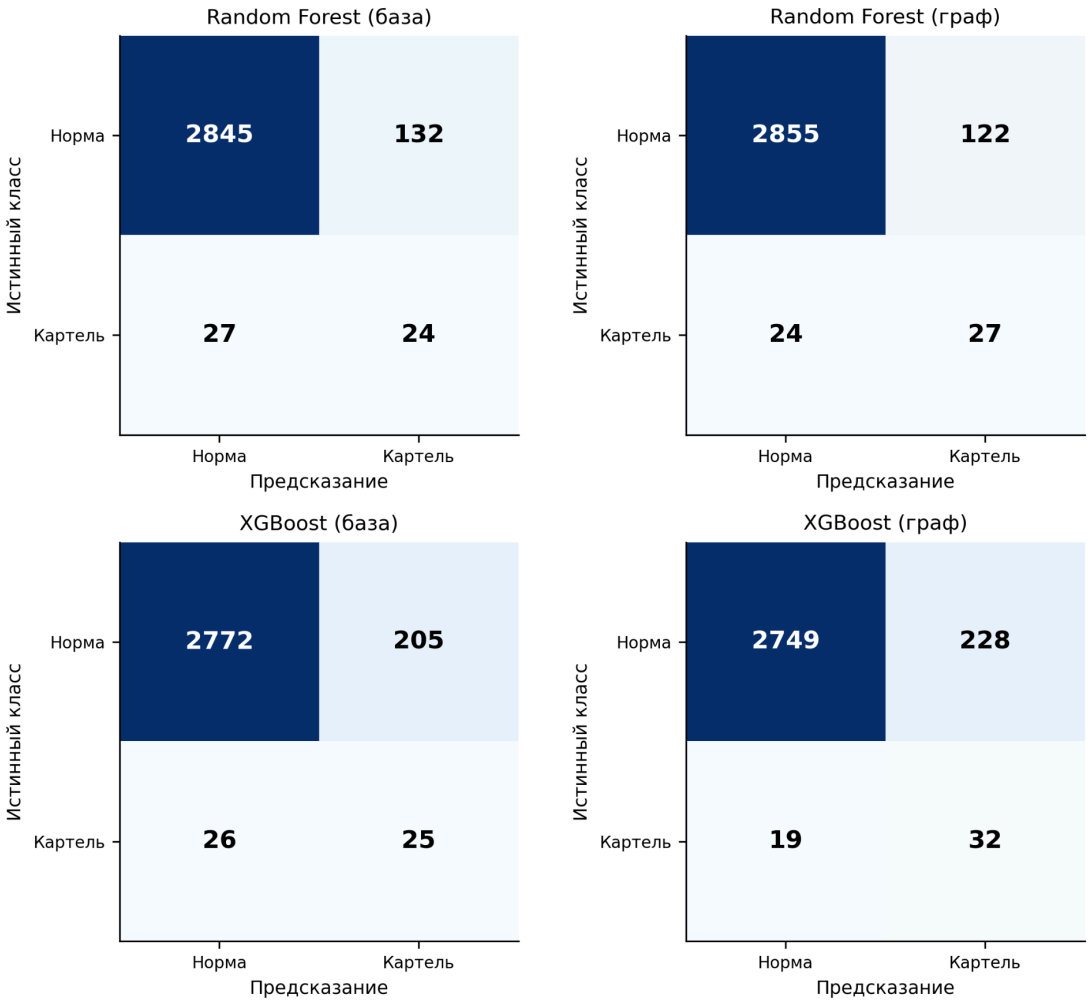


Рис. 4. Матрицы ошибок четырех ML-моделей на тестовой выборке

Лучшую сбалансированную модель Random Forest на графовых признаках можно охарактеризовать так: для выявления 27 действительных картелей контролеру потребуется проверить 149 помеченных закупок, иными словами среди подмножества, выделенного моделью, доля картелей составляет 18,1 % против исходных 1,7 % во всей выборке. Это эквивалентно увеличению концентрации картелей в подвыборке для проверки в 10,6 раза (показатель lift), что и составляет основную практическую ценность скрининга.

5.4. Важность признаков

Анализ важности признаков для модели Random Forest на графовых признаках представлен на Рис. 5. Наибольший вклад в предсказание вносят отношение цены к НМЦ (0,210) и логарифм НМЦ (0,148), за ними следуют процент снижения цены и месяц публикации (по 0,095). Среди графовых признаков наибольшую важность имеют концентрация победителя в регионе (0,093) и доля несостоявшихся торгов в регионе (0,081). Признак накопленного числа побед поставщика (0,074) также входит в число значимых.

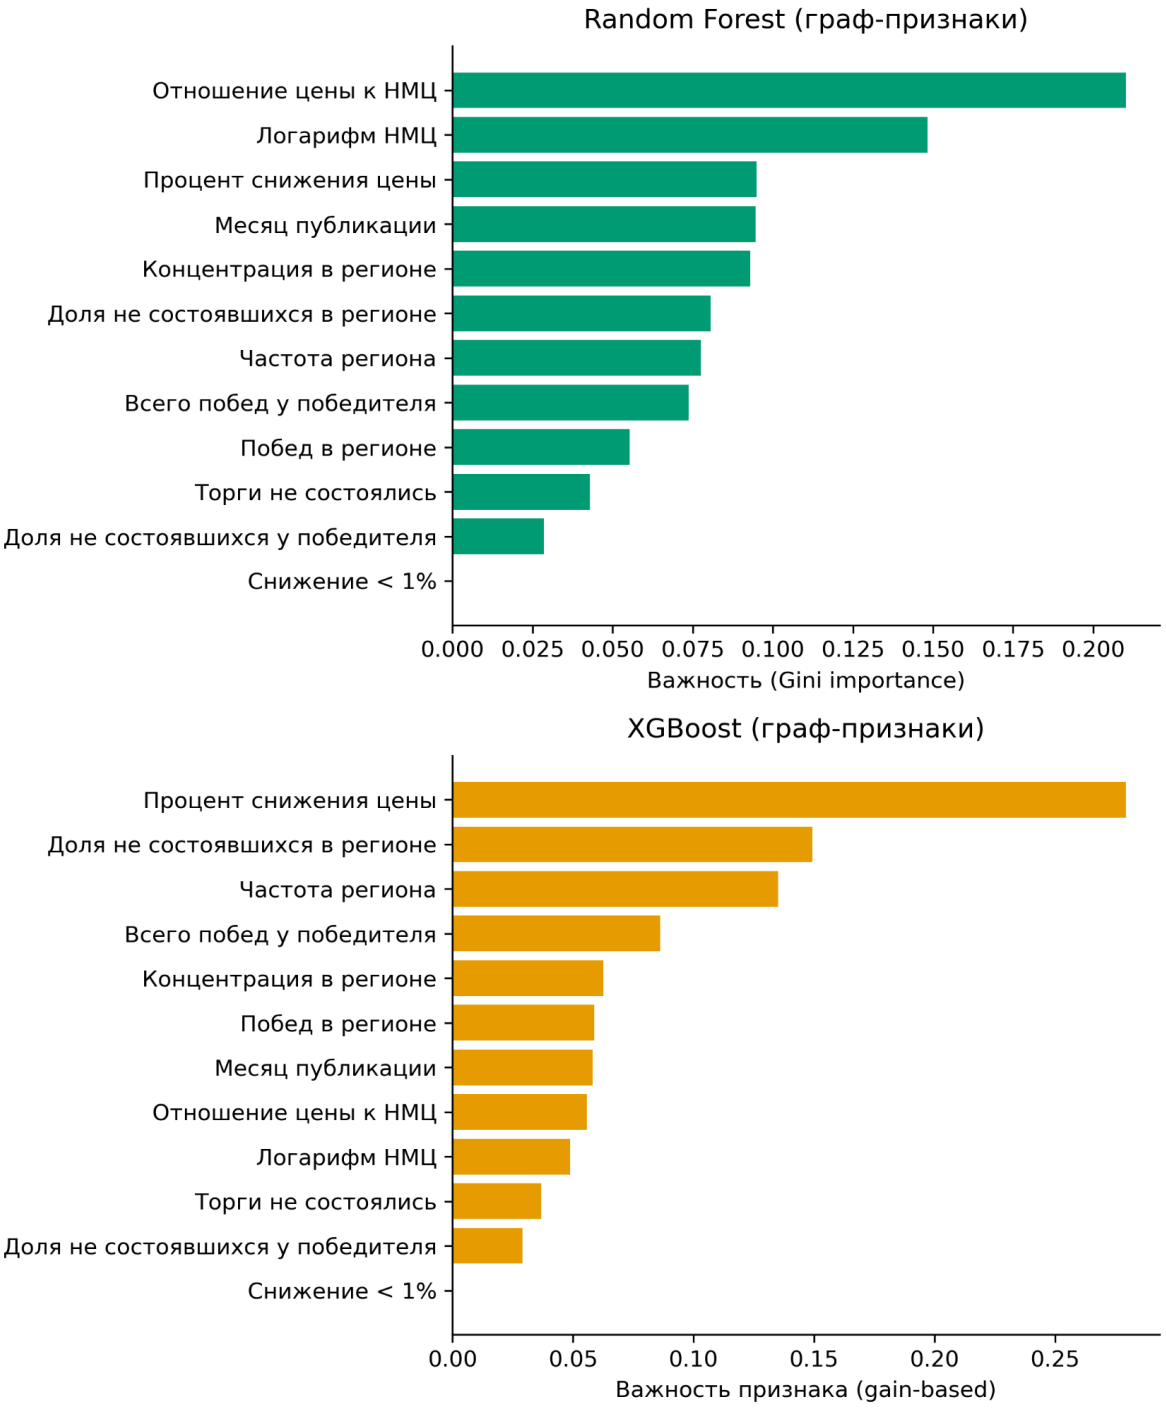


Рис. 5. Важность признаков в модели Random Forest (графовые признаки)

Распределение важности признаков для модели XGBoost на графовых признаках качественно отличается. На первом месте у XGBoost процент снижения цены (0,279), на втором стоит доля несостоявшихся торгов в регионе (0,149), на третьем является частота региона (0,135). Отношение цены к НМЦ и логарифм НМЦ у XGBoost получают существенно меньшие веса (0,056 и 0,049 соответственно). Различие объясняется механизмом работы алгоритмов. Random Forest усредняет важность признаков по большому числу независимых деревьев, тогда как XGBoost последовательно строит

деревья, корректирующие ошибки предыдущих, и распределяет вес более неравномерно. Несмотря на это различие, обе модели сходятся в том, что ценовые признаки являются наиболее информативными, отличается лишь то, какая именно ценовая характеристика занимает первое место.

5.5. Кросс - валидация и устойчивость модели

Для обеспечения надежности оценок применена пятикратная стратифицированная кросс-валидация на обучающей выборке в двух режимах. В первую очередь, подбор гиперпараметров модели Random Forest выполнен через RandomizedSearchCV (n_iter=30, cv=5, scoring='f1', random_state=42), где наилучшая конфигурация (n_estimators=363, max_depth=29, min_samples_leaf=1) достигла F1-score 0,975 на кросс-валидации. Это значение существенно завышено, поскольку SMOTE применялся ко всей обучающей выборке до разбиения на блоки, и синтетические наблюдения попадали одновременно в обучающие и валидационные блоки. Итоговая оценка качества выполнялась на независимой тестовой выборке. Затем, для оценки устойчивости ранжирования моделей проведена отдельная 5-кратная кросс-валидация всех пяти конфигураций без SMOTE-аугментации, что дает честный пофолдовый разброс F1-score, представленный на Рис. 6.

Рис. 6 иллюстрирует распределение F1-score по пяти фолдам для каждой модели. Логистическая регрессия демонстрирует стабильно низкий F1 (медиана ≈ 0,065, межквартильный размах менее 0,01), фактически результат устойчивый, но практически бесполезный. Все четыре ансамблевые модели существенно превосходят ее на каждом из пяти фолдов, что подтверждает суждение о том, что превосходство ансамблей не является артефактом конкретного разбиения. Среди ансамблей наилучшую стабильность и медианный F1-score показывает RF (граф) (медиана ≈ 0,250, узкий ящик с усами в диапазоне 0,24-0,31), тогда как RF (база) имеет более широкий разброс с выбросом на уровне 0,306. XGBoost на графовых признаках занимает второе место по медиане (≈ 0,230) при меньшем разбросе по сравнению с XGB (база), медиана которого опускается до ≈ 0,215. Медианные значения кросс-валидации согласуются с результатами на тестовой выборке (Таблица 1), что свидетельствует об отсутствии переобучения и воспроизводимости рейтинга моделей при изменении состава обучающих данных.

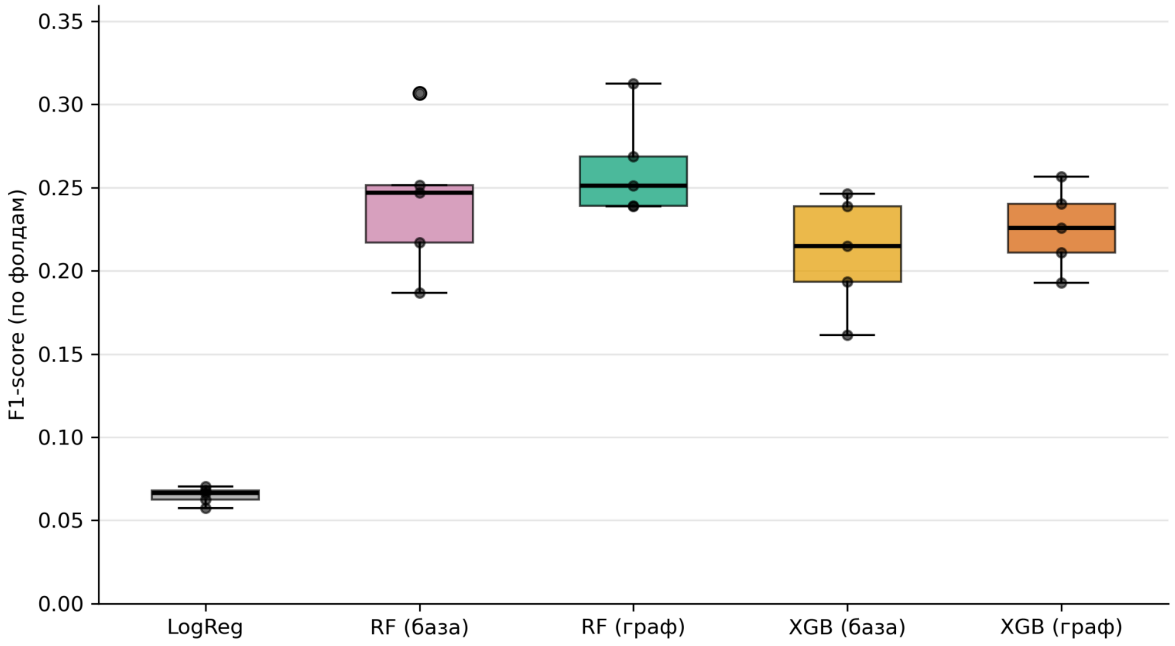


Рис. 6. Распределение F1-score по фолдам 5-кратной кросс-валидации (без SMOTE)

Для оценки статистической значимости полученных различий между моделями и устойчивости F1-score на отложенной тестовой выборке проведен стратифицированный бутстрэп (2 000 итераций). На каждой итерации картельные и некартельные наблюдения тестовой выборки ресэмплировались с возвращением раздельно, что сохраняет долю положительного класса (1,7 %) в каждой бутстрэп-реплике и позволяет корректно оценивать метрики при выраженном дисбалансе. По полученным распределениям рассчитаны 95-процентные доверительные интервалы (CI) для F1-score, Precision и Recall, представленные в Таблице 2.

Модель	**F1**	**95% CI F1**	**95% CI Precision**	**95% CI Recall**
Логистическая регрессия	0,059	[0,049; 0,070]	[0,025; 0,036]	[0,569; 0,824]
RF базовые признаки	0,232	[0,170; 0,295]	[0,112; 0,199]	[0,333; 0,608]
RF граф-признаки	0,270	[0,203; 0,339]	[0,137; 0,231]	[0,392; 0,667]
XGBoost базовые признаки	0,178	[0,130; 0,227]	[0,079; 0,139]	[0,353; 0,627]
XGBoost граф-признаки	0,206	[0,164; 0,249]	[0,098; 0,150]	[0,490; 0,765]

Таблица 2. Точечные оценки и 95 % доверительные интервалы метрик на тестовой выборке (стратифицированный бутстрэп, 2 000 итераций)

Полученные интервалы позволяют сделать несколько содержательных наблюдений. Во-первых, доверительный интервал F1-score для логистической регрессии [0,049; 0,070] полностью отделен от интервалов всех четырех ансамблевых моделей и не имеет с ними

точек пересечения. Вследствии чего превосходство ансамблей над линейным бенчмарком носит статистически устойчивый характер и не объясняется случайным колебанием состава тестовой выборки. Во-вторых, доверительные интервалы четырех ансамблевых моделей перекрываются между собой, интервал RF на графовых признаках [0,203; 0,339] пересекается с интервалом RF на базовых признаках [0,170; 0,295] в диапазоне [0,203; 0,295]. В-третьих, для XGBoost на графовых признаках доверительный интервал Recall [0,490; 0,765] устойчиво превышает аналогичные интервалы остальных моделей, что доказывает его роль как модели с приоритетом полноты выявления.

Сопоставление двух независимых процедур валидации бутстрэпа на тестовой выборке и 5-кратной стратифицированной кросс-валидации без SMOTE представлено в Таблице 3. Согласованность точечных оценок F1 на тесте с распределениями по фолдам CV служит дополнительным аргументом в пользу отсутствия переобучения.

Модель	**F1 на тесте**	**95% CI F1 (bootstrap)**	**CV mean F1**	**CV std**
Логистическая регрессия	0,059	[0,049; 0,070]	0,066	0,005
RF базовые признаки	0,232	[0,170; 0,295]	0,152	0,091
RF граф-признаки	0,270	[0,203; 0,339]	0,174	0,082
XGBoost базовые признаки	0,178	[0,130; 0,227]	0,241	0,034
XGBoost граф-признаки	0,206	[0,164; 0,249]	0,250	0,046

Таблица 3. Сводное сравнение оценок F1-score: бутстрэп на тестовой выборке и 5-кратная стратифицированная кросс-валидация (без SMOTE)

Для логистической регрессии оценки практически совпадают (0,059 на тесте против 0,066 в CV), а CV-разброс минимален (std = 0,005), что отражает стабильно низкое качество линейной модели. Для семейства Random Forest точечная оценка на тесте систематически превышает CV mean (0,270 против 0,174 у RF на графовых признаках), однако бутстрэп-CI [0,203; 0,339] полностью перекрывает CV-распределение, медиана которого по Рис. 6 составляет приблизительно 0,250. Расхождение объясняется тем, что тестовое разбиение с random_state = 42 оказалось более благоприятным для Random Forest, чем средний фолд кросс-валидации, но смещение находится в пределах статистической погрешности. Для XGBoost наблюдается обратная картина, где CV mean (0,250 у графовой версии) превышает точечную оценку на тесте (0,206), при этом бутстрэп-CI [0,164; 0,249] также накрывает CV-распределение. Таким образом, рейтинг моделей по F1 устойчиво воспроизводится между двумя независимыми процедурами валидации, а абсолютные значения метрик согласованы в пределах доверительных интервалов.

Совокупность результатов бутстрэпа и кросс-валидации позволяет квалифицировать полученные оценки качества как воспроизводимые. Принципиальный вывод о превосходстве ансамблевых методов над логистической регрессией статистически значим. Вывод о приросте качества при добавлении графовых признаков подтверждается направлением эффекта в обеих процедурах валидации, но требует подтверждения на большей выборке для достижения статистической значимости.

5.6. Проверка гипотез

Гипотеза H1 (ансамблевые методы превосходят логистическую регрессию по F1-score) подтверждается: F1-score всех четырех ML-моделей (от 0,178 у XGBoost на базовых признаках до 0,270 у Random Forest на графовых признаках) превышает F1-score логистической регрессии (0,059), превосходство наблюдается также по числу верно выявленных картелей при значительно меньшем числе ложных срабатываний.

Гипотеза H2 (ценовые признаки вносят наибольший вклад) подтверждается. Для Random Forest первые три позиции по важности занимают ценовые и масштабные характеристики: отношение цены к НМЦ, логарифм НМЦ и процент снижения цены. Для XGBoost на первой позиции стоит процент снижения цены, еще одна ценовая характеристика. В результате, конкретное ранжирование ценовых признаков различается между моделями, но обе модели указывают на ценовые характеристики как на наиболее информативные предикторы сговора.

Гипотеза H3 (закупки с высокой концентрацией победителя в регионе чаще связаны со сговором) подтверждается частично. Гипотеза H3 в ее исходной сетевой формулировке (компании, регулярно участвующие в одних и тех же закупках вместе, с большей вероятностью являются участниками картеля) в настоящей работе не проверена в полном объеме, поскольку признаки прямого совместного участия фирм не были реализованы. Проверена же гипотеза о связи структурной концентрации регионального рынка с вероятностью сговора и эта версия подтверждается частично. Признак концентрации победителя в регионе входит в число значимых для обеих моделей (важность 0,093 у Random Forest и 0,063 у XGBoost), а добавление графовых признаков улучшает качество обеих ансамблевых моделей. Вместе с тем вклад графовых признаков уступает вкладу ценовых, а признак накопленного числа побед имеет умеренную важность и слабо коррелирует с меткой картеля. Полное подтверждение гипотезы H3 требует реализации признаков прямых сетевых связей (совместное участие фирм в одних и тех же закупках), что обсуждается в разделах 6 и 7.

6. Обсуждение

Исходя из полученных результатов, мы можем сказать, что модель машинного обучения способна классифицировать запросы котировок по признаку наличия сговора заметно лучше случайного угадывания и линейного бенчмарка. Наилучшей моделью по F1-score является Random Forest, которая на графовых признаках достигает F1 = 0,270, что более чем в четыре раза превышает значение у логистической регрессии (0,059) при одновременном сокращении числа ложных срабатываний на порядок (122 против 1 128). Результат согласуется с порядком величин, полученным в зарубежной литературе на закупочных данных Швейцарии, Испании и Канады (Huber и Imhof, 2019; García Rodríguez et al., 2022; Barot, 2023). Ниже результаты обсуждаются в разрезе трех гипотез и теоретических положений обзора литературы.

6.1. Превосходство ансамблевых методов (H1)

Подтверждение H1 повторяет на российских данных результат García Rodríguez et al. (2022) и Barot (2023). Ансамбли устойчиво обыгрывают логистическую регрессию. Причина в том, что связь между признаками закупки и вероятностью сговора нелинейна и носит пороговый характер. Скажем, высокое отношение цены к НМЦ настораживает только в паре с низким снижением цены, а признак несостоявшихся торгов значит разное для дешевых и дорогих контрактов. Линейная модель такие взаимодействия не ловит, отсюда и крайне низкая точность (Precision = 0,031). Она срабатывает почти на каждой закупке, подозрительной хотя бы по одному признаку. Решающие деревья в ансамбле, наоборот, естественно описывают пороговые правила и их сочетания.

Random Forest на графовых признаках дает лучший баланс по F1 умеренные и точность (0,181), и полнота (0,529). XGBoost на тех же признаках ведет себя по другому, у него самая высокая полнота из всех моделей (Recall = 0,627), он находит 32 картеля из 51, но платит за это числом ложных срабатываний (228 против 122 у Random Forest). Бустинг раз за разом цепляется к трудным наблюдениям, и при экстремальном дисбалансе с scale_pos_weight = 58,7 это раздувает полноту в ущерб точности. Отсюда практический момент, выбирать модель нужно не по агрегированным метрикам, а по тому, какая ошибка дороже регулятору. Нельзя пропустить ни одного картеля, пусть и ценой лишних проверок (минимизация FN), тогда берем XGBoost. Важнее сберечь ограниченные ресурсы контролёра, то есть держать баланс точности и полноты - Random Forest.

6.2. Доминирование ценовых признаков (H2)

Подтверждение гипотезы H2 подкрепляет центральное положение работы Huber и Imhof (2019) о том, что ценовые показатели несут наиболее сильный предсказательный сигнал. Обе ансамблевые модели сошлись на ценовых признаках как наиболее информативных, но по-разному распределили вес между ними. Random Forest на первое место поставил отношение цены к НМЦ (0,210) и логарифм НМЦ (0,148), тогда как XGBoost выявил процент снижения цены (0,279) как наиболее важный. Все три признака описывают одно и то же отсутствие реальной ценовой конкуренции, но через разные числовые характеристики. Низкий процент снижения цены и близкое к единице отношение цены к НМЦ это статистически взаимосвязанные индикаторы одной и той же экономической ситуации, когда контракт заключается практически без торга. Различие в их ранжировании между моделями объясняется механизмом расчета важности: Random Forest усредняет вклад признаков по большому числу независимых деревьев, тогда как XGBoost при последовательном построении деревьев может закрепить сигнал на одном из коррелированных признаков и далее использовать его интенсивнее.

Процедура запроса котировок построена на ценовой конкуренции, и именно ценовые показатели наиболее непосредственно отражают ее отсутствие. При картельном сговоре победитель не имеет стимула снижать цену, поскольку конкуренты подают заведомо проигрышные «технические» заявки или не подают их вовсе. В результате контракт заключается вблизи начальной цены, а процент снижения стремится к нулю. Высокая важность логарифма НМЦ, в свою очередь, отражает то, что вероятность и тип сговора зависят от масштаба контракта, то есть более крупные контракты создают больший стимул к координации.

Важность признака в ансамблевой модели и его парная линейная корреляция с целевой переменной это разные величины. Слабые линейные корреляции всех признаков (по модулю менее 0,10) при этом не противоречат высокой предсказательной способности моделей. Сигнал возникает именно из нелинейных сочетаний признаков, а не из их индивидуальной связи с откликом.

6.3. Роль структурных и графовых признаков (H3)

Частичное подтверждение гипотезы H3 неоднозначно в плане интерпретации. С одной стороны, добавление графовых признаков улучшило качество обеих ансамблевых моделей. Для Random Forest F1-score вырос с 0,232 до 0,270 (рост на 16 %), а число верно

выявленных картелей с 24 до 27. Для XGBoost число верно выявленных картелей увеличилось с 25 до 32 (рост на 28 %). Результат отражает выводы Ishii (2007) и Wallimann et al. (2022) в том, что устойчивые структурные паттерны взаимодействия участников несут информацию о сговоре. Признаки концентрации победителя в регионе и доли несостоявшихся торгов в регионе вошли в число значимых для обеих моделей.

С другой стороны, вклад графовых признаков уступил вкладу ценовых, а признак накопленного числа побед поставщика показал умеренную важность и слабую линейную связь с меткой картеля. Вероятное объяснение этого эффекта связано со способом разметки. Метка is_cartel присвоена закупкам, победители которых фигурируют в уже раскрытых делах ФАС, тогда как поставщики с наибольшим числом побед это, как правило, крупные легальные участники рынка, еще не попавшие под антимонопольное преследование. Другими словами, графовые признаки в текущей реализации описывают доминирование на рынке, которое лишь косвенно связано с раскрытым сговором. Потенциал сетевого подхода признаков совместного участия фирм в одних и тех же закупках, заявленных в первоначальном замысле, в настоящей работе реализован частично и является приоритетным направлением дальнейшего развития.

6.4. Устойчивость результатов и ограничения внутренней валидности

Результаты получены на единственном стратифицированном разбиении выборки с фиксированным значением random_state, а подбор гиперпараметров Random Forest выполнялся на пятиблочной кросс-валидации. Высокое значение F1-score на кросс-валидации (0,975) при умеренном значении на тесте (0,270) указывает на то, что применение SMOTE к обучающей выборке завышает оценку. Наблюдения, сгенерированные SMOTE на основе картельных примеров обучающей выборки, попадают одновременно в обучающие и валидационные блоки кросс-валидации, и модель фактически валидируется на наблюдениях, очень похожих на те, на которых обучалась. Это известное ограничение процедуры SMOTE при использовании внутри кросс-валидации, именно поэтому итоговая оценка качества во всех случаях выполнялась на независимой тестовой выборке, к которой SMOTE не применялся и которая сохранила исходную пропорцию классов (1,7 % картелей).

Дополнительной проверкой устойчивости служат две независимые процедуры, представленные в разделе 5.5. Стратифицированный бутстрэп тестовых предсказаний (2 000 итераций) дает 95 % доверительные интервалы F1-score, не зависящие от выбора конкретного train/test-разбиения, независимая 5-кратная кросс-валидация без SMOTE проверяет, что рейтинг моделей сохраняется при ротации обучающей и валидационной

частей. Согласованность результатов между этими процедурами повышает доверие к выводам, но имеющиеся ограничения должны интерпретироваться с учетом конкретных свойств полученных интервалов.

Ключевой вывод гипотезы H1 формирует суждение о превосходстве ансамблевых методов над логистической регрессией. Бутстрэп-CI логистической регрессии [0,049; 0,070] полностью отделен от интервалов всех четырех ансамблевых моделей (нижние границы которых не опускаются ниже 0,130 у XGBoost на базовых признаках). Этот вывод устойчив и не объясняется случайным отклонением состава тестовой выборки.

Более того, прирост в F1 при добавлении графовых признаков (с 0,232 до 0,270 для Random Forest и с 0,178 до 0,206 для XGBoost) демонстрирует постоянное направление эффекта в обеих процедурах валидации, однако доверительные интервалы базовой и графовой версий частично перекрываются. Например, для Random Forest интервалы [0,170; 0,295] и [0,203; 0,339] пересекаются в диапазоне [0,203; 0,295]. При имеющемся объеме положительного класса (всего 51 картельная закупка в тесте) различия не достигают уровня статистической значимости и для убедительного подтверждения требуют расширения выборки или применения более чувствительных тестов парных сравнений (Тест МакНемара на парных предсказаниях). С практической точки зрения наблюдаемый эффект остается содержательным и согласуется с теоретическими ожиданиями, изложенными в разделе 6.3.

Заметим, что среднее значение F1 по фолдам кросс-валидации (CV mean) и медиана CV-распределения могут заметно различаться при большом разбросе по фолдам. Для RF на графовых признаках CV std = 0,082, и медиана CV (≈ 0,250 по Рис. 6) существенно ближе к тестовой оценке F1 = 0,270, чем CV mean (0,174). Тестовая оценка лежит внутри 95 % бутстрэп-CI [0,203; 0,339], который полностью накрывает CV-распределение, поэтому различие тестового F1 и CV mean не свидетельствует о переобучении, а отражает чувствительность среднего к нескольким «плохим» фолдам. Это видно по тому, что тестовое разбиение с random_state = 42 оказалось благоприятным для семейства Random Forest, а для XGBoost ситуация обратная (CV mean 0,250 при тестовом F1 0,206), где точечный F1 на тесте (0,206) ниже как медианы CV (≈ 0,230), так и среднего CV (0,250), но все еще лежит внутри 95 % бутстрэп-CI [0,164; 0,249]. Оба несовпадения находятся в пределах статистической погрешности.

Для повышения надежности выводов в дальнейших исследованиях целесообразно применять вложенную кросс-валидацию, при которой SMOTE вызывается внутри каждого обучающего блока отдельно, а валидационный блок остается несбалансированным, а также повторять процедуру оценки на нескольких случайных разбиениях (multiple random

seeds) для дополнительного контроля за зависимостью результатов от конкретного разбиения. Эти направления более подробно обсуждаются в разделе 7.

6.5. Обсуждение практических импликаций

Практическое применение разработанного инструмента предполагает его встраивание в двухуровневый процесс принятия решений. На первом уровне модель машинного обучения выполняет функцию автоматизированного скрининга, где из потока миллионов тендеров, публикуемых в ЕИС ежегодно, она выделяет подмножество закупок с наиболее высокой расчетной вероятностью сговора. Наилучшая модель Random Forest на графовых признаках повышает концентрацию картелей в подвыборке для проверки в 10,6 раза (lift = 10,6). Среди 149 помеченных закупок доля картелей составляет 18,1 % против 1,7 % во всей выборке. Специалист, проверяющий помеченные закупки, затрачивает на выявление одного картеля примерно в 10 раз меньше ресурсов, чем при случайной выборке из общего потока.

На втором уровне каждая закупка, помеченная моделью как подозрительная, передается эксперту-аналитику для углубленной проверки, в которую входит изучение документации, анализ состава участников, сопоставление с ранее выявленными схемами и при необходимости инициирование официального расследования ФАС. Модель не принимает окончательных решений и не выносит обвинений, она лишь выполняет роль приоритизации объектов контроля.

Существенную роль в процессе принятия решений играет управление рисками двух типов ошибок. Ошибка I рода (ложное срабатывание, FP) означает, что добросовестная компания попадает под проверку, что создает для нее репутационные и операционные издержки, а также нерационально расходует ресурсы регулятора. В наилучшей сбалансированной модели 122 ложных срабатывания из 3 028 тестовых закупок приемлемый уровень при условии, что сам факт помещения закупки в список проверки не влечет автоматических правовых последствий. Ошибка II рода (пропущенный картель, FN) означает, что сговорная закупка остается вне поля зрения, что влечет прямые потери бюджетных средств и искажение рыночной конкуренции. Регулятор должен явно определить, какая из ошибок обходится дороже, и в соответствии с этим выбрать модель и порог классификации, при приоритете полноты (минимизация FN) предпочтительна модель XGBoost с Recall = 0,627, при приоритете баланса точности и полноты Random Forest с F1 = 0,270. Промежуточное значение порога классификации позволяет настроить

компромисс между этими ошибками под конкретные операционные условия антимонопольного органа.

7. Заключение

Настоящая работа была посвящена проверке применимости методов машинного обучения для обнаружения картельных сговоров в процедурах запроса котировок на российских закупочных данных. На выборке из 15 138 закупок, размеченных по решениям ФАС, было обучено и сопоставлено три семейства классификаторов с использованием ценовых, структурных и графовых признаков. Проведенный анализ позволяет сформулировать следующие выводы.

Во-первых, машинное обучение является работоспособным инструментом скрининга запросов котировок. Наилучшая модель - Random Forest на графовых признаках достигла F1-score 0,270, что более чем вчетверо превышает значение у логистической регрессии (0,059), при одновременном сокращении числа ложных срабатываний с 1 128 до 122. XGBoost на графовых признаках показал наивысшую полноту среди всех моделей (Recall = 0,627), верно выявляя 32 картеля из 51. Это дает положительный ответ на исследовательский вопрос и подтверждает принципиальную возможность перехода от реактивного антимонопольного контроля, инициируемого жалобами, к проактивному автоматизированному мониторингу.

Во-вторых, подтвердилось превосходство ансамблевых методов (Random Forest и XGBoost) над логистической регрессией по метрике F1-score (гипотеза H1). Связь характеристик закупки с вероятностью сговора носит нелинейный и пороговый характер, который линейная модель воспроизвести не способна. В конечном счете вывод может экстраполироваться не только на рынках других стран, но и на российских данных.

В-третьих, наибольший вклад в предсказание сговора вносят ценовые признаки, такие как отношение цены договора к НМЦ и процент снижения цены (гипотеза H2). Это закономерно для процедуры, сама природа которой состоит в ценовой конкуренции. При сговоре контракт заключается вблизи начальной цены, а снижение стремится к нулю. Графовые признаки региональной концентрации улучшают качество моделей, но их вклад уступает ценовым, в связи с чем гипотеза H3 подтверждена частично.

Теоретический вклад работы состоит в эмпирической проверке переносимости методологии автоматического обнаружения картелей на российский институциональный контекст 44-ФЗ. Показано, что ценовые маркеры сговора, выявленные в зарубежной литературе, сохраняют предсказательную силу и на отечественных данных. Практический вклад заключается в демонстрации готового пайплайна скрининга, который может быть использован антимонопольным органом для приоритизации проверок. Ранжирование

закупок по выходной вероятности модели позволяет сфокусировать ограниченные ресурсы контролеров на наиболее подозрительных процедурах. В количественном выражении наилучшая модель повышает концентрацию картелей в подмножестве для проверки в 10,6 раза по сравнению со случайной выборкой (lift = 10,6), что соответствует доле картелей 18,1 % среди помеченных закупок против 1,7 % во всей выборке.

Ограничения исследования

Работа имеет ряд ограничений. Первое и главное это неполнота разметки. Метка сговора присвоена лишь закупкам, победители которых фигурируют в уже раскрытых делах ФАС, тогда как нераскрытые картели попадают в класс «без сговора», что систематически занижает оценку качества. Также выборка географически несбалансирована, то есть значительная доля наблюдений приходится на ограниченное число регионов, что ограничивает внешнюю валидность выводов. Применение SMOTE при кросс-валидации смещает оценку F1 в сторону завышения (0,975 на CV против 0,270 на тесте). Наконец, графовые признаки в текущей реализации описывают рыночное доминирование, но не прямые сетевые связи совместного участия фирм.

Направления дальнейших исследований

Перечисленные ограничения определяют направления развития работы. Первостепенное значение имеет оптимальная реализация признаков совместного участия, частота встреч одних и тех же фирм в одних и тех же закупках и территориальная близость участников, что позволит полноценно проверить сетевую гипотезу H3. Далее, перспективным расширением является применение графовых нейросетей с механизмом внимания (GAT) по методологии Imhof et al. (2025), напрямую моделирующих структуру связей между поставщиками. К тому же, для интерпретации индивидуальных предсказаний следует внедрить анализ SHAP-значений (Lundberg и Lee, 2017), декомпозирующих каждое решение модели на вклады отдельных признаков. В конце концов, повышение надежности оценок требует перехода к вложенной кросс-валидации с балансировкой внутри обучающих блоков и проверки устойчивости результатов на нескольких случайных разбиениях. Реализация этих направлений позволит приблизить инструмент скрининга к стадии практического внедрения в работу антимонопольного органа.

8. Список литературы

1. *Федеральный закон "О контрактной системе в сфере закупок товаров, работ, услуг для обеспечения государственных и муниципальных нужд" от 05.04.2013 N 44-ФЗ (последняя редакция) \ КонсультантПлюс*. (n.d.). https://www.consultant.ru/document/cons_doc_LAW_144624/
2. *Федеральный закон "О закупках товаров, работ, услуг отдельными видами юридических лиц" от 18.07.2011 N 223-ФЗ (последняя редакция) \ КонсультантПлюс*. (n.d.). https://www.consultant.ru/document/cons_doc_LAW_116964/
3. Федеральная антимонопольная служба. (н.д.). Федеральная антимонопольная служба. https://br.fas.gov.ru/
4. *N 135-ФЗ Статья 11. Запрет на ограничивающие конкуренцию соглашения хозяйствующих субъектов \ КонсультантПлюс*. (n.d.). https://www.consultant.ru/document/cons_doc_LAW_61763/75fad2ba0bd186dad16ff04a2efe55ae3f9ff7e6/
5. Lyra, M. S., Damásio, B., Pinheiro, F. L., & Bacao, F. (2022). Fraud, corruption, and collusion in public procurement activities, a systematic literature review on data-driven methods. *Applied Network Science*, *7*(1). https://doi.org/10.1007/s41109-022-00523-6
6. Ishii, R. (2007). *Collusion in Repeated Procurement Auction: a Study of Paving Market in Japan. ideas.repec.org*. https://ideas.repec.org/p/osk/wpaper/0716.html
7. Decarolis, F., & Giorgiantonio, C. (2022). Corruption red flags in public procurement: new evidence from Italian calls for tenders. *EPJ Data Science*, *11*(1). https://doi.org/10.1140/epjds/s13688-022-00325-x
8. Huber, M. &. I. D. (2019). Machine learning with screens for detecting bid-rigging cartels. Huber, M., & Imhof, D. (2019). Machine learning with screens for detecting bid-rigging cartels. International Journal of Industrial Organization, 65, 277–301. [C1] ideas.repec.org. https://ideas.repec.org/a/eee/indorg/v65y2019icp277-301.html
9. Ralha, C. G., & Silva, C. V. S. (2012). A multi-agent data mining system for cartel detection in Brazilian government procurement. *Expert Systems with Applications, 39*(14), 11642–11656. https://www.researchgate.net/publication/236945929_A_multi-agent_data_mining_system_for_cartel_detection_in_Brazilian_government_procurement
10. García Rodríguez, M. J., Rodríguez-Montequín, V., Ballesteros-Pérez, P., Love, P. E. D., & Signor, R. (2022). Collusion detection in public procurement auctions with machine

learning algorithms. *Expert Systems with Applications, 177*, 114967. https://www.sciencedirect.com/science/article/pii/S0926580521004982

11. Barot, R. (2023). *Detecting collusion in public procurement: A comparative study of machine learning models* (Master's thesis, Concordia University). https://spectrum.library.concordia.ca/id/eprint/993368/1/BAROT_MSCM_S2024.pdf
12. Rodríguez, M. J. G., Montequín, V. R., Fernández, F. O., & Balsera, J. M. V. (2020). Bidders Recommender for Public Procurement Auctions Using Machine Learning: Data Analysis, Algorithm, and Case Study with Tenders from Spain. *Complexity*, *2020*, 1–20. https://doi.org/10.1155/2020/8858258
13. Wallimann, H., Imhof, D., & Huber, M. (2022). A machine learning approach for flagging incomplete bid-rigging cartels. *Computational Economics, 62*(4), 1669–1720. https://doi.org/10.1007/s10614-022-10315-w
14. Wallimann, H., & Sticher, S. (2023). On suspicious tracks: Machine-learning based approaches to detect cartels in railway-infrastructure procurement. *Utilities Policy, 82*, 101537. https://www.sciencedirect.com/science/article/pii/S0967070X23002482
15. Huber, M., & Imhof, D. (2021, April 22). *Deep learning for detecting bid rigging: Flagging cartel participants based on convolutional neural networks*. arXiv.org. https://arxiv.org/abs/2104.11142
16. Imhof, D., Viklund, E. W., & Huber, M. (2025). *Catching bid-rigging cartels with graph attention neural networks*. arXiv. https://arxiv.org/abs/2507.12369
17. Andres, M., Bruttel, L., & Friedrichsen, J. (2023). How communication makes the difference between a cartel and tacit collusion: A machine learning approach. *European Economic Review, 152*, 104331. https://doi.org/10.1016/j.euroecorev.2022.104331
18. Sadoune, I., Joanis, M., & Lodi, A. (2024). *Algorithmic collusion and the minimum price Markov game*. arXiv. https://arxiv.org/abs/2407.03521
19. Lundberg, S. M., & Lee, S. (2017). *A unified approach to interpreting model predictions*. https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html
20. Головщинский, К. И., & Шамрин, А. Т. (2021). *Исследование уровня коррупции при государственных закупках. Институт государственного и муниципального управления НИУ ВШЭ.* https://www.rbc.ru/economics/20/12/2021/61bc5d059a794770833e7b51
21. ТАСС. (2021, 8 июля). *Объем государственных и корпоративных закупок в 2020 году в России составил 27% ВВП.* https://tass.ru/ekonomika/11850

Приложение №1

Полный код исследования, включая загрузку и предобработку данных, конструирование признаков, обучение моделей, подбор гиперпараметров, расчет метрик и построение визуализаций, размещен в открытом репозитории на GitHub:

https://github.com/dstrayoung614-bot/Course-project-cartel-detection/tree/main